

英文文献分析

Ghorbian, Mohsen, Mostafa Ghobaei-Arani, and Rohollah Asadolahpour-Karimi. "Function placement approaches in serverless computing: A survey." *Journal of Systems Architecture* 157 (2024): 103291.

这篇文章的重要性在于它对无服务器计算中的函数放置问题提供了系统性、全面性的综述，为研究函数迁移、函数切片以及基于深度学习和强化学习的方法提供了明确的理论基础和研究框架。首先，文章梳理了现有的函数放置策略，包括基于机器学习的方法、启发式方法和模型驱动方法，这对于研究者理解不同方法在资源调度、延迟优化和成本控制中的适用场景和局限性至关重要，尤其是在动态环境和异构资源条件下，函数放置决策面临高度不确定性，这正是深度强化学习可以发挥作用的关键点。其次，通过对各类方法的优缺点分析，该文帮助开发者和研究者明确哪些方法在处理高频请求波动、动态负载和资源约束时表现更优，从而为函数迁移和切片策略的设计提供参考。此外，文章还指出了当前研究中存在的空白和挑战，例如针对实时性要求的优化不足、模型在大规模边缘环境中的泛化能力有限等，这为将深度强化学习引入函数放置和迁移问题提供了理论动机和实践方向。

Li, Yongkang, et al. "Serverless computing: state-of-the-art, challenges and opportunities." *IEEE Transactions on Services Computing* 16.2 (2022): 1522-1539.

该论文系统地剖析了无服务器计算基础设施中“函数迁移与放置”所面临的三大核心瓶颈：启动延迟、弱隔离性与粗粒度调度。其中，第 3.2.3 节“调度策略”深入对比了集中式与分布式调度的优劣，并尖锐指出传统基于服务器的调度机制无法适应函数级细粒度、短生命周期、突发并发的特性，这直接导致了函数放置的效率低下和资源浪费。论文更进一步，在 3.2.1 与 3.2.3 节中提出通过“检查点/恢复”和“核心级调度”等技术来优化函数状态迁移与资源绑定，为降低迁移开销、实现更精细的函数放置提供了关键技术路径。尤为重要的是，在第 5.1 节“资源管理中的机器学习”中，论文明确将“函数放置”列为资源自动扩展的三个关键阶段之一，并主张使用强化学习根据运行时反馈动态调整资源配置，这为利用 DRL 实现智能、自适应、低成本的函数迁移与放置决策奠定了坚实的理论基础和研究方向。

Shafiei, Hossein, Ahmad Khonsari, and Payam Mousavi. "Serverless computing: a survey of opportunities, challenges, and applications." *ACM Computing Surveys* 54.11s (2022): 1-32.

该论文从实际应用场景出发，为“函数迁移与放置”及“深度学习/强化学习”的应用提供了丰富的实证依据和分类框架。论文第 5.3 节“调度”构建了一个详尽的调度器分类法（如能源感知、资源感知、工作流感知等），这实质上是对不同“函数放置策略”的系统性归纳。例如，“数据感知调度”直接关联“将函数放置于数据附近”这一核心优化问题，而“工作流感知调度”则关注如何基于函数调用链进行预测性放置以降低冷启动。这些分类为设计基于 DRL 的智能调度器提供了清晰的问题定义和优化目标。更重要的是，第 5.1 节明确指出了当前工具在建模复杂函数交互和工作流方面的不足，这恰恰是 DRL 可以发挥作用的领域——通过学习和推理复杂状态空间来优化放置决策。同时，论文对边缘计算中函数放置面临的网络延迟和安全等新约束的讨论，为 DRL 研究开辟了具有挑战性的现实应用场景。

Gao, Xiangqiang, et al. "Dynamic resource allocation for virtual network function placement in satellite edge clouds." *IEEE Transactions on Network Science and Engineering* 9.4 (2022): 2252-2265.

研究了卫星边缘云环境中虚拟网络函数的动态资源分配与放置问题,提出了一种分布式 VNF 放置算法 D-VNFP,旨在联合优化网络带宽成本和服务端到端时延。该论文对“无服务器计算中的函数放置”和“函数切片”领域具有显著重要性,因为它将 VNF 视为可切片部署的网络功能单元,并在动态、资源受限的卫星边缘环境中实现了分布式、自适应的函数放置与资源调度。论文不仅考虑了多用户、多卫星间的资源竞争与协同问题,还通过 Viterbi 算法和路径选择策略实现了低延迟、低成本的服务链构建。这一研究扩展了无服务器和网络功能虚拟化的应用边界,为未来空天地一体化网络中的服务部署提供了可行的分布式优化框架,尤其对远程地区、海洋、灾害应急等场景下的边缘智能服务具有重要支撑作用

Bermbach D, Bader J, Hasenburg J, Pfandzelter T, Thamsen L. AuctionWhisk: Using an auction-inspired approach for function placement in serverless fog platforms. *Softw Pract Exper.* 2022; 52(5): 1143–1169. doi:[10.1002/spe.3058](https://doi.org/10.1002/spe.3058)

本论文提出了一种基于拍卖机制的分散式函数放置方法 AuctionWhisk,用于在无服务器雾计算平台中动态调度函数。通过引入存储和执行两种竞价机制,允许应用开发者根据资源需求 and 经济意愿进行竞标,而雾节点则根据竞价和本地资源情况自主决定是否执行或卸载函数。该方法无需集中式调度器,能够在线、分散地工作,适用于资源受限的边缘环境。论文还通过仿真和基于 OpenWhisk 的原型实验验证了该方法的有效性,表明其能在不丢弃请求的前提下最大化节点收益。该研究对“无服务器计算中的函数迁移或函数放置”领域具有重要意义,因为它提供了一种经济驱动、可扩展且去中心化的调度机制,能够在动态、异构的雾环境中实现高效资源分配,为边缘计算和物联网场景下的函数部署提供了新思路。

Huang, Wei, et al. "Online Learning for Function Placement in Serverless Computing." *2025 IEEE 11th International Conference on Network Softwarization (NetSoft)*. IEEE, 2025.

该论文提出了一种基于多臂老虎机 (Multi-Armed Bandits) 的在线学习算法,用于在无服务器计算环境中动态优化虚拟函数 (Virtual Function) 的放置策略,以最小化执行成本并满足资源约束。该算法通过置信区间估计和线性规划求解,实现了在未知动态环境中快速学习最优放置策略的能力,并在实验中表现出良好的收敛性和计算效率。论文还提出了一种加速技术,通过减少策略更新频率来提升算法在大型网络中的实用性。该工作对于无服务器计算中的函数放置问题具有重要意义,因为它首次将在线学习与约束优化结合,提供了一种既具有理论保证又易于实现的解决方案,能够适应网络条件的动态变化,显著降低了传统启发式或基于神经网络方法的高计算成本和长训练时间,为实际部署提供了可行路径。

Russo, Gabriele Russo, Valeria Cardellini, and Francesco Lo Presti. "A framework for offloading and migration of serverless functions in the Edge-Cloud Continuum." *Pervasive and Mobile Computing* 100 (2024): 101915.

该文章提出并实现了 Serverledge,这是一个专为边缘-云连续体设计的无服务器函数计算框架。该论文的核心贡献在于设计并实现了函数的水平与垂直卸载机制,以及运行中函数迁移功能,填补了现有 FaaS 框架在分布式地理环境中的调度与迁移能力不足的空白。通过引入请求转发与 HTTP 重定向两种卸载策略,并设计自适应选择算法,系统能够根据网络延迟动态优化卸载路径,显著降低响应时间。此外,该研究还整合了容器实时迁移技术(基于 CRIU),支持同步与异步函数的迁移,增强了系统在负载均衡和资源动态调配方面的灵活性。这些机制对于无服务器计算在边缘场景中的实际部署至关重要,因为它们直接解决了边缘节点资源受限、网络异构性强和延迟敏感等问题,为函数迁移与放置提供了可扩展、低延迟的解决方案

案。

Nardelli, Matteo, and Gabriele Russo Russo. "Function offloading and data migration for stateful serverless edge computing." *Proceedings of the 15th ACM/SPEC International Conference on Performance Engineering*. 2024.

该论文研究了在边缘-云环境中如何协同优化有状态函数的卸载与其关联数据的迁移问题。作者提出了一个名为 DS2P 的去中心化有状态无服务器平台，并设计了 SLO 感知的函数卸载策略与基于整数线性规划 (ILP) 的数据迁移策略，旨在满足用户定义的服务等级目标 (SLO) 同时最小化响应时间和数据迁移开销。论文通过仿真实验验证了所提策略在降低延迟、减少 SLO 违约率方面的有效性。该研究对有状态无服务器计算领域至关重要，因为它首次系统地建模了函数与数据之间的依赖关系，并提出了在分布式环境中同时优化函数放置与数据位置的协同机制，为支持低延迟、有状态的服务（如实时数据分析、交互式应用）提供了理论依据与实现路径。

Shahid, Urooba, et al. "Latency-sensitive function placement among heterogeneous nodes in serverless computing." *Sensors* 24.13 (2024): 4195.

该论文提出了一种基于机器学习的自适应函数放置模型，旨在解决异构边缘-云环境中延迟敏感型函数的部署问题。通过 XGBoost 回归器预测函数执行时间、决策树回归器预测网络延迟，并结合用户定义的服务质量 (QoS) 与截止时间要求，系统能够动态选择最优的计算节点（边缘或云端）来执行函数。论文还通过视频监控场景进行实证验证，结果表明该模型在满足截止时间和优化资源利用率方面优于传统的启发式算法（如 Best Fit 和 Round Robin）。该工作对无服务器计算中的函数放置领域具有重要意义，因为它首次将非线性机器学习模型引入到函数放置决策中，能够处理异构节点环境下的动态负载和网络变化，从而提升系统的响应速度与资源效率，为延迟敏感型应用（如 IoT、实时视频处理）提供了可扩展且自适应的部署框架。

Liu, Xuanzhe, et al. "Faaslight: General application-level cold-start latency optimization for function-as-a-service in serverless computing." *ACM Transactions on Software Engineering and Methodology* 32.5 (2023): 1-29.

该论文提出了一种面向应用程序的冷启动优化方法 FaaSLight，通过静态分析识别并分离函数中的“可选代码”，仅加载执行必需的“不可或缺代码”，从而显著减少代码加载时间和冷启动延迟。该方法支持 Python 和 JavaScript，并兼容主流无服务器平台（如 AWS Lambda、Google Cloud Functions），无需修改底层基础设施。实验表明，FaaSLight 平均可减少 28.78% 的代码加载延迟和 19.21% 的总响应延迟。该工作对函数切片与冷启动优化领域极为重要，因为它首次应用层实现了跨平台、跨语言的通用化代码瘦身机制，为开发者提供了一种轻量级、非侵入式的性能提升方案，尤其适合依赖大型第三方库的复杂函数，有助于推动无服务器计算在延迟敏感场景中的广泛应用。

Qiu, Haoran, et al. "SIMPPPO: A scalable and incremental online learning framework for serverless resource management." *Proceedings of the 13th Symposium on Cloud Computing*. 2022.

该论文针对无服务器计算中多租户环境下函数迁移与动态放置、资源切片等核心挑战，提出

了一种基于多智能体强化学习的协同决策框架 SIMPPO。它通过引入“虚拟智能体”和辅助全局状态建模其他函数行为，有效解决了传统单智能体强化学习在环境非平稳性下训练不收敛、资源竞争导致的 SLO 违背问题。在函数迁移与放置方面，SIMPPO 实现了基于实时负载和 SLO 感知的自适应资源调配，显著降低尾延迟并提升资源利用率；在函数切片层面，其支持细粒度的垂直与水平伸缩机制，通过多智能体协调避免切片冲突和资源碎片化；在深度学习强化学习领域，该工作为多智能体 PPO 在动态系统控制中的实用化提供了重要范本，通过状态空间约简、增量训练和参数共享，推动了 DRL 在复杂云原生场景中的可扩展落地，对构建高性能、自适应的无服务器基础设施具有关键意义。

Mampage, Anupama, Shanika Karunasekera, and Rajkumar Buyya. "Deep Reinforcement Learning for Scheduling Applications in Serverless and Serverful Hybrid Computing Environments." *IEEE Transactions on Services Computing* (2025).

该论文的核心贡献是设计了一个基于近端策略优化的双层 actor-critic 深度强化学习模型，以解决在混合无服务器与 IaaS 集群间的请求级调度问题。其创新点在于将调度决策分解为两个层次：第一层选择执行环境（无服务器或虚拟机），第二层在选定环境中挑选具体节点。该框架通过状态向量实时捕获节点资源利用率、请求特征和集群行为模式，并将冷启动延迟、资源空闲成本等转化为奖励信号进行优化。实验证明，该方法能根据工作负载的波动性（如突发流量或稳定高负载）动态切换部署模式，例如在低负载时使用无服务器避免 VM 空转成本，在高负载时切换至 VM 集群以降低频繁冷启动带来的延迟。这种细粒度的混合调度策略，使得在保持响应时间的同时，将用户成本降低了最高 44%，为云服务商实现智能化的跨平台资源协调提供了可落地的算法基础。

Raza, Ali, et al. "Configuration and placement of serverless applications using statistical learning." *IEEE Transactions on Network and Service Management* 20.2 (2023): 1065-1077.

该论文提出的 COSE 框架利用贝叶斯优化来解决无服务器函数配置和放置的两个具体难题：内存分配和位置选择（边缘或核心云）。其技术核心是通过高斯过程建模，仅用少量样本（如 5-15 次函数调用）即可预测函数在不同配置下的运行时间与成本曲线，并以此为基础，使用整数线性规划为函数 workflow（如 DAG）寻找满足端到端延迟约束的最小成本配置组合。该研究的实际意义在于，它提供了一种低采样开销、能自适应环境变化的自动化配置方法。例如，实验显示对于图像处理 workflow，COSE 能根据 SLO 严格程度动态调整各函数的内存大小并切换部署位置（在延迟敏感时使用高价低延迟的边缘节点，否则使用低成本的核心云）。这种方法直接优化了函数级别的“切片”策略和跨地理位置的“放置”决策，为多函数无服务器应用的成本效益优化提供了数据驱动的解决方案。

Wen, Jinfeng, et al. "Rise of the planet of serverless computing: A systematic review." *ACM Transactions on Software Engineering and Methodology* 32.5 (2023): 1-61.

本文收集并分析了 164 篇核心文献，构建了包含 17 个研究方向的分类学，系统地总结了从性能优化、编程框架到应用迁移、安全测试等方方面面的现有解决方案与实验评估方法。该文章之所以对“函数迁移/放置、函数切分、深度学习/强化学习”领域至关重要，是因为它提供了不可或缺的研究蓝图与基准。在函数迁移与放置方面，文章不仅归纳了手动与自动转换的方法（如 Node2FaaS、DAF），更在资源管理章节深度剖析了基于应用特征、平台 QoS 和动态调整的多种调度与放置策略（如 Kraken、Caerus），为优化函数部署位置以降低成本、

提升性能指明了技术路径。在函数切分（或更广义的编排与组合）方面，文章在“编程框架”和“状态管理”部分总结了函数融合、工作流调度和状态保持的多种框架（如 WUKONG、Beldi），为解决复杂应用的分解与协同执行问题提供了关键见解。最后，文章明确指出机器学习（特别是深度学习）是无服务器计算的重要应用场景，并专门总结了为 ML/DL 设计的特定框架（如 SIREN、BATCH），以及利用强化学习进行资源调度与优化的研究趋势，为 AI 与无服务器计算的深度结合奠定了坚实的文献基础，帮助研究者快速定位核心挑战与前沿方向。

Jain, Prakhar, et al. "POSEIDON: Efficient Function Placement at the Edge Using Deep Reinforcement Learning." *International Conference on Service-Oriented Computing*. Singapore: Springer Nature Singapore, 2024.

这篇论文提出的“POSEIDON”框架对于无服务器计算在边缘环境中的函数迁移与放置问题具有重要贡献。其核心在于利用深度强化学习（DRL）中的近端策略优化（PPO）算法，动态优化函数在资源受限的边缘节点上的部署位置，同时考虑了延迟、资源消耗和服务成本等多重目标。与传统的整数规划或启发式方法相比，该框架显著提升了决策效率，能够更快地响应动态工作负载和用户移动性。该方法不仅提升了边缘无服务器系统的能效和实时性，也为结合 DRL 的自动化资源管理提供了可行路径。

Zolfaghari, Behrooz, et al. "Dynamic function placement and request scheduling of serverless workflows in edge environment." *IEEE Transactions on Services Computing* (2025).

提出了一种面向边缘环境下无服务器工作流的动态函数放置与请求调度架构 DFPS，将问题分解为初始函数放置、请求调度和动态调整三个阶段，并分别采用 NSGA-II 算法、图模式匹配和模拟退火技术进行优化。该论文对“无服务器计算中的函数迁移或函数放置”领域极为重要，因为它首次在边缘环境中针对工作流场景引入了动态函数放置与周期性调整机制，有效解决了传统方法中存在的函数实例复用率低、冷启动频繁以及响应延迟高等问题。相比现有方法中按请求逐次优化的策略，DFPS 通过建立初始放置基准并基于运行需求进行动态再调整，显著降低了工作流平均完成时间，提升了资源利用效率，为边缘无服务器系统的可扩展性、自适应性和实时性提供了系统性解决方案，尤其适合物联网和低延迟应用场景，对推动无服务器计算在边缘环境中的落地具有重要理论与实践意义。

Abdi, Mania, et al. "Palette load balancing: Locality hints for serverless functions." *Proceedings of the eighteenth European conference on computer systems*. 2023.

该论文提出了“Palette”负载均衡机制，通过引入“颜色”作为局部性提示，使无服务器函数能够表达执行亲和性，从而将相关调用路由到同一实例上，减少数据移动和网络开销。该机制保持了无服务器模型的简洁性，用户无需直接管理实例，平台则可利用颜色提示优化调度。论文在社交网络缓存、Dask 和 NumS 等应用中验证了其有效性，显著提升了缓存命中率和任务执行效率。该研究对于无服务器计算中的函数调度与局部性优化至关重要，因为它解决了当前无服务器平台中数据局部性缺失的关键瓶颈，通过轻量级的 API 扩展实现了近似有服务器部署的性能，为数据密集型应用在无服务器环境中的高效运行提供了实用且可扩展的解决方案。

Li, Huifang, et al. "Weighted double deep Q-network based reinforcement learning for bi-objective multi-workflow scheduling in the cloud." *Cluster Computing* 25.2 (2022):

751-768.

该论文提出的加权双深度 Q 网络强化学习 (WDDQN-RL) 框架为无服务器计算中的函数放置与迁移提供了重要的方法论借鉴。在无服务器场景下, 函数调度面临动态请求、异构资源与多目标优化 (如延迟与成本) 的挑战, 本文通过基于指针网络的两级调度策略, 能够有效处理动态候选任务集 (类似函数调用序列), 实现任务排序与资源分配的协同优化。其引入的动态感知机制 (DSM) 支持根据用户偏好调整目标权重, 有助于在函数切片与资源分配中实现多目标权衡。此外, WDDQN 中的动态系数自适应平衡机制提升了动作值估计的准确性, 为基于深度强化学习的实时调度决策提供了更稳定、高效的解决方案, 适用于无服务器环境中高动态、多目标的函数调度与资源管理问题。

Chen, Genxin, et al. "A collaborative scheduling method for cloud computing heterogeneous workflows based on deep reinforcement learning." *Future Generation Computer Systems* 141 (2023): 284-297.

通过将 D3QN 深度强化学习与高维多目标优化相结合, 为函数调度领域提供了创新性解决方案。论文构建了一个同时优化任务完工时间、执行成本、服务公平性和任务连续性的强化学习模型, 其核心价值在于为解决函数调度中多目标冲突这一经典难题提供了数据驱动的协同优化新范式。论文设计了即时-滞后复合奖励机制, 将四个优化目标整合到 D3QN 算法的训练框架中。同时提出了多层任务状态感知算法 (Algorithm 1), 精确提取异构工作流中任务层级、计算量和空闲等待时间等关键特征。更关键的是, 论文设计了**均衡策略 (Algorithm 2)**和**优先级策略 (Algorithm 3)**两种互补的任务预加载机制, 前者保障工作流间的资源公平性, 后者优先调度高完成度工作流以加速整体执行。这些方法与虚拟机偏好策略结合, 形成了完整的高维调度动作空间。该研究的直接贡献是为函数切片和函数放置决策提供了智能化的多目标协同调度框架, 尤其在动态、异构且资源受限的边缘云环境中, 为如何平衡延迟、成本、公平性和服务连续性提供了可实施的技术路径。

Jayanetti, Amanda, Saman Halgamuge, and Rajkumar Buyya. "Multi-agent deep reinforcement learning framework for renewable energy-aware workflow scheduling on distributed cloud data centers." *IEEE Transactions on Parallel and Distributed Systems* 35.4 (2024): 604-615.

该论文提出了一种基于多智能体深度强化学习 (MARL) 的分层调度框架, 用于在由可再生能源供电的分布式云数据中心中优化工作流任务的调度, 以最小化棕色能源使用并控制任务完成时间。该框架采用集中式训练与分布式执行模式, 通过局部观察和信息共享来应对部分可观测环境中的非平稳性问题, 并利用领域知识设计层次化智能体结构以提升训练效率。实验表明, 该框架在能源消耗和任务执行时间方面均优于对比算法。该工作对于无服务器计算中的函数调度与资源管理具有重要意义, 因为它将 MARL 应用于复杂、动态且部分可观测的多云环境中, 为绿色计算和可持续云运营提供了智能自适应的调度方案, 同时也为边缘计算等分布式环境中的任务调度提供了可扩展的解决思路。

J. Du, L. Zhao, J. Feng and X. Chu, "Computation Offloading and Resource Allocation in Mixed Fog/Cloud Computing Systems With Min-Max Fairness Guarantee," in *IEEE Transactions on Communications*, vol. 66, no. 4, pp. 1594-1608, April 2018, doi: 10.1109/TCOMM.2017.2787700.

该论文针对多用户在雾计算与云平台混合环境中的任务卸载问题, 提出了一种保证最小-最大公平性的联合优化算法。其关键在于将原始混合整数非线性规划问题转化为可通过半定松

弛处理的 QCQP 问题，并设计了 CORA 算法依次解决卸载决策、计算资源分配和无线资源分配。该研究的重要性在于，它首次在考虑边缘计算场景下，同时优化了卸载位置（本地、雾节点、云中心）、CPU 分配、发射功率和带宽分配，并以最小化最大用户加权成本为目标，确保了不同信道条件下的用户公平性。该模型特别适用于物联网等场景，其中设备计算能力有限且任务具有延迟约束。通过严格的数学转换和迭代算法，该工作为函数切片和跨层迁移提供了理论框架，使得在资源受限的边缘环境中实现高效、公平的任务分发成为可能。